

House Prices - kaggle

AUTHORS

Ana Maria F Costa

Eduarda da Silva Brito

Maria Helena Ramos de Macedo

1. Introdução e contextualização do problema

1.1 Objetivo geral

Analisar os fatores determinantes na precificação de imóveis residenciais utilizando modelagem estatística, a fim de ajudar as imobiliárias a determinar os preços dos imóveis.

1.2 Objetivo específico

- Identificar e quantificar a relação entre a área construída e o preço de venda.
- Avaliar o impacto da localização e da proximidade do centro no valor dos imóveis.
- Desenvolver um modelo de regressão linear múltiplo com alto poder explicativo e diagnosticar suas suposições.

2. Fundamentação Teórica

2.1 Regressão Linear Múltipla

2.2 Precificação Hedônica

3. Descrição da base de dados

- **SalePrice (Preço de Venda)** - the property's sale price in dollars. This is the target variable that you're trying to predict. (o preço de venda do imóvel em dólares. Esta é a variável alvo que você está tentando prever.)
- **MSSubClass:** The building class (Classe do edifício)
- **MSZoning:** The general zoning classification (Classificação geral de zoneamento)
- **LotFrontage:** Linear feet of street connected to property (Metros lineares de rua conectados à propriedade)
- **LotArea:** Lot size in square feet (Tamanho do lote em pés quadrados)
- **Street:** Type of road access (Tipo de acesso viário)
- **Alley:** Type of alley access (Tipo de acesso por viela)
- **LotShape:** General shape of property (Formato geral da propriedade)
- **LandContour:** Flatness of the property (Planicidade da propriedade)

- **Utilities:** Type of utilities available (Tipo de serviços públicos disponíveis)
- **LotConfig:** Lot configuration (Configuração do lote)
- **LandSlope:** Slope of property (Inclinação da propriedade)
- **Neighborhood:** Physical locations within Ames city limits (Localização física dentro dos limites da cidade de Ames)
- **Condition1:** Proximity to main road or railroad (Proximidade à estrada principal ou ferrovia)
- **Condition2:** Proximity to main road or railroad (if a second is present) (Proximidade à estrada principal ou ferrovia - se houver uma segunda)
- **BldgType:** Type of dwelling (Tipo de residência)
- **HouseStyle:** Style of dwelling (Estilo de residência)
- **OverallQual:** Overall material and finish quality (Qualidade geral do material e acabamento)
- **OverallCond:** Overall condition rating (Classificação geral da condição)
- **YearBuilt:** Original construction date (Data de construção original)
- **YearRemodAdd:** Remodel date (Data da última reforma)
- **RoofStyle:** Type of roof (Tipo de telhado)
- **RoofMatl:** Roof material (Material do telhado)
- **Exterior1st:** Exterior covering on house (Revestimento externo da casa)
- **Exterior2nd:** Exterior covering on house (if more than one material) (Rev ext da casa se houver mais de um material)
- **MasVnrType:** Masonry veneer type (Tipo de revestimento de alvenaria)
- **MasVnrArea:** Masonry veneer area in square feet (Área de revestimento de alvenaria em pés quadrados)
- **ExterQual:** Exterior material quality (Qualidade do material externo)
- **ExterCond:** Present condition of the material on the exterior (Condição atual do material no exterior)
- **Foundation:** Type of foundation (Tipo de fundação)
- **BsmtQual:** Height of the basement (Altura do porão)
- **BsmtCond:** General condition of the basement (Condição geral do porão)
- **BsmtExposure:** Walkout or garden level basement walls (Paredes do porão com saída

para o jardim ou nível do jardim)

- **BsmtFinType1:** Quality of basement finished area (Qualidade da área acabada do porão)
- **BsmtFinSF1:** Type 1 finished square feet (Área acabada do tipo 1 em pés quadrados)
- **BsmtFinType2:** Quality of second finished area (if present) (Qualidade da segunda área acabada - se houver)
- **BsmtFinSF2:** Type 2 finished square feet (Área acabada do tipo 2 em pés quadrados)
- **BsmtUnfSF:** Unfinished square feet of basement area (Área inacabada do porão em pés quadrados)
- **TotalBsmtSF:** Total square feet of basement area (Área total do porão em pés quadrados)
- **Heating:** Type of heating (Tipo de aquecimento)
- **HeatingQC:** Heating quality and condition (Qualidade e condição do aquecimento)
- **CentralAir:** Central air conditioning (Ar condicionado central)
- **Electrical:** Electrical system (Sistema elétrico)
- **1stFlrSF:** First Floor square feet (Área do primeiro andar)
- **2ndFlrSF:** Second floor square feet (Área do segunda andar)
- **LowQualFinSF:** Low quality finished square feet (all floors) (Área acabada de baixa qualidade - todos os andares)
- **GrLivArea:** Above grade (ground) living area square feet (Área habitável acima do nível do solo)
- **BsmtFullBath:** Basement full bathrooms (Banheiros completos no subsolo)
- **BsmtHalfBath:** Basement half bathrooms (Lavabos no subsolo)
- **FullBath:** Full bathrooms above grade (Banheiros completos acima do nível do solo)
- **HalfBath:** Half baths above grade (Lavabos acima do nível do solo)
- **Bedroom:** Number of bedrooms above basement level (Número de quartos acima do nível do solo)
- **Kitchen:** Number of kitchens (Números de cozinhas)
- **KitchenQual:** Kitchen quality (Qualidade da cozinha)
- **TotRmsAbvGrd:** Total rooms above grade (does not include bathrooms) (Total de cômodos acima do nível do solo - NÃO inclui banheiros)
- **Functional:** Home functionality rating (Classificação da funcionalidade da casa)
- **Fireplaces:** Number of fireplaces (Lareiras)

- **FireplaceQu:** Fireplace quality (Qualidade da lareira)
- **GarageType:** Garage location (Localização da garagem)
- **GarageYrBlt:** Year garage was built (Ano de construção da garagem)
- **GarageFinish:** Interior finish of the garage (Acabamento interno da garagem)
- **GarageCars:** Size of garage in car capacity (Tamanho da garagem em carros - capacidade)
- **GarageArea:** Size of garage in square feet (Tamanho da garagem em pés quadrados)
- **GarageQual:** Garage quality (Qualidade da garagem)
- **GarageCond:** Garage condition (Condição da garagem)
- **PavedDrive:** Paved driveway (Entrada pavimentada)
- **WoodDeckSF:** Wood deck area in square feet (Área do deck de madeira em pés quadrados)
- **OpenPorchSF:** Open porch area in square feet (Área da varanda aberta em pés quadrados)
- **EnclosedPorch:** Enclosed porch area in square feet (Área da varanda fechada em pés quadrados)
- **3SsnPorch:** Three season porch area in square feet (Área da varanda de três estações em pés quadrados)
- **ScreenPorch:** Screen porch area in square feet (Área da varanda telada em pés quadrados)
- **PoolArea:** Pool area in square feet (Área da piscina em pés quadrados)
- **PoolQC:** Pool quality (Qualidade da piscina)
- **Fence:** Fence quality (Qualidade da cerca)
- **MiscFeature:** Miscellaneous feature not covered in other categories (Característica diversa não coberta em outras categorias)
- **MiscVal:** \$Value of miscellaneous feature (Valor da característica diversa)
- **MoSold:** Month Sold (Mês da venda)
- **YrSold:** Year Sold (Ano da venda)
- **SaleType:** Type of sale (Tipo de venda)
- **SaleCondition:** Condition of sale (Condição da venda)

4. Preparação dos dados

► Code

```
Using virtual environment '/home/delfos/.virtualenvs/r-reticulate' ...
```

```
+ /home/delfos/.virtualenvs/r-reticulate/bin/python -m pip install --upgrade --no-user ipython
```

► Code

```
Python 3.14.5 (/home/delfos/.virtualenvs/r-reticulate/bin/python)
Reticulate 1.46.0 REPL -- A Python interpreter in R.
Enter 'exit' or 'quit' to exit the REPL and return to R.
```

```
exit
```

4.1 Dados faltantes

Aqui os dados com *NA*s são dados onde a casa não tem garagem, ou cerca, ou piscina. *Não* são dados incompletos. Logo, não se usa o ajuste substituindo os dados pela média ou mediana. Mas substituindo *NA* por “*None*” em variáveis categóricas. E *NA* por 0, em variáveis numéricas.

► Code

	Id	MSSubClass	MSZoning	...	SaleType	SaleCondition	SalePrice
0	1	60	RL	...	WD	Normal	208500
1	2	20	RL	...	WD	Normal	181500
2	3	60	RL	...	WD	Normal	223500
3	4	70	RL	...	WD	Abnorml	140000
4	5	60	RL	...	WD	Normal	250000

```
[5 rows x 81 columns]
```

► Code

```
<class 'pandas.DataFrame'>
RangeIndex: 1460 entries, 0 to 1459
Data columns (total 81 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Id                    1460 non-null  int64
1   MSSubClass            1460 non-null  int64
2   MSZoning              1460 non-null  str
3   LotFrontage          1201 non-null  float64
4   LotArea              1460 non-null  int64
5   Street               1460 non-null  str
6   Alley               91 non-null    str
7   LotShape             1460 non-null  str
8   LandContour          1460 non-null  str
9   Utilities            1460 non-null  str
10  LotConfig            1460 non-null  str
11  LandSlope            1460 non-null  str
12  Neighborhood          1460 non-null  str
13  Condition1           1460 non-null  str
14  Condition2           1460 non-null  str
15  BldgType             1460 non-null  str
```

15	StugType	1460	non-null	str
16	HouseStyle	1460	non-null	str
17	OverallQual	1460	non-null	int64
18	OverallCond	1460	non-null	int64
19	YearBuilt	1460	non-null	int64
20	YearRemodAdd	1460	non-null	int64
21	RoofStyle	1460	non-null	str
22	RoofMatl	1460	non-null	str
23	Exterior1st	1460	non-null	str
24	Exterior2nd	1460	non-null	str
25	MasVnrType	588	non-null	str
26	MasVnrArea	1452	non-null	float64
27	ExterQual	1460	non-null	str
28	ExterCond	1460	non-null	str
29	Foundation	1460	non-null	str
30	BsmtQual	1423	non-null	str
31	BsmtCond	1423	non-null	str
32	BsmtExposure	1422	non-null	str
33	BsmtFinType1	1423	non-null	str
34	BsmtFinSF1	1460	non-null	int64
35	BsmtFinType2	1422	non-null	str
36	BsmtFinSF2	1460	non-null	int64
37	BsmtUnfSF	1460	non-null	int64
38	TotalBsmtSF	1460	non-null	int64
39	Heating	1460	non-null	str
40	HeatingQC	1460	non-null	str
41	CentralAir	1460	non-null	str
42	Electrical	1459	non-null	str
43	1stFlrSF	1460	non-null	int64
44	2ndFlrSF	1460	non-null	int64
45	LowQualFinSF	1460	non-null	int64
46	GrLivArea	1460	non-null	int64
47	BsmtFullBath	1460	non-null	int64
48	BsmtHalfBath	1460	non-null	int64
49	FullBath	1460	non-null	int64
50	HalfBath	1460	non-null	int64
51	BedroomAbvGr	1460	non-null	int64
52	KitchenAbvGr	1460	non-null	int64
53	KitchenQual	1460	non-null	str
54	TotRmsAbvGrd	1460	non-null	int64
55	Functional	1460	non-null	str
56	Fireplaces	1460	non-null	int64
57	FireplaceQu	770	non-null	str
58	GarageType	1379	non-null	str
59	GarageYrBlt	1379	non-null	float64
60	GarageFinish	1379	non-null	str
61	GarageCars	1460	non-null	int64
62	GarageArea	1460	non-null	int64
63	GarageQual	1379	non-null	str
64	GarageCond	1379	non-null	str
65	PavedDrive	1460	non-null	str
66	WoodDeckSF	1460	non-null	int64
67	OpenPorchSF	1460	non-null	int64
68	EnclosedPorch	1460	non-null	int64

```

69 3SsnPorch      1460 non-null  int64
70 ScreenPorch   1460 non-null  int64
71 PoolArea      1460 non-null  int64
72 PoolQC        7 non-null    str
73 Fence         281 non-null  str
74 MiscFeature    54 non-null    str
75 MiscVal       1460 non-null  int64
76 MoSold        1460 non-null  int64
77 YrSold        1460 non-null  int64
78 SaleType      1460 non-null  str
79 SaleCondition 1460 non-null  str
80 SalePrice     1460 non-null  int64
dtypes: float64(3), int64(35), str(43)
memory usage: 924.0 KB

```

► Code

```

PoolQC      1453
MiscFeature 1406
Alley       1369
Fence       1179
MasVnrType   872
FireplaceQu 690
LotFrontage 259
GarageQual   81
GarageFinish 81
GarageType   81
GarageYrBlt  81
GarageCond   81
BsmtFinType2 38
BsmtExposure 38
BsmtCond     37
BsmtQual     37
BsmtFinType1 37
MasVnrArea    8
Electrical    1
Condition2    0
BldgType      0
Neighborhood  0
LandSlope     0
LotConfig     0
Condition1    0
LandContour   0
LotShape      0
Street        0
LotArea       0
MSSubClass    0
MSZoning      0
Id            0
Utilities     0
HouseStyle    0
Foundation    0
ExterQual     0

```

ExterCond	0
BsmtUnfSF	0
TotalBsmtSF	0
Heating	0
BsmtFinSF1	0
Exterior2nd	0
Exterior1st	0
RoofMatl	0
RoofStyle	0
YearRemodAdd	0
OverallQual	0
YearBuilt	0
OverallCond	0
BsmtHalfBath	0
BsmtFullBath	0
GrLivArea	0
LowQualFinSF	0
2ndFlrSF	0
1stFlrSF	0
CentralAir	0
HeatingQC	0
BsmtFinSF2	0
Fireplaces	0
TotRmsAbvGrd	0
KitchenQual	0
KitchenAbvGr	0
Functional	0
FullBath	0
HalfBath	0
GarageCars	0
GarageArea	0
BedroomAbvGr	0
PavedDrive	0
EnclosedPorch	0
3SsnPorch	0
OpenPorchSF	0
WoodDeckSF	0
PoolArea	0
ScreenPorch	0
MiscVal	0
MoSold	0
YrSold	0
SaleType	0
SaleCondition	0
SalePrice	0

dtype: int64

► Code

PoolQC	99.520548
MiscFeature	96.301370
Alley	93.767123
Fence	80.753425
MasVnrType	59.726027

FireplaceQu	47.260274
LotFrontage	17.739726
GarageQual	5.547945
GarageFinish	5.547945
GarageType	5.547945
GarageYrBlt	5.547945
GarageCond	5.547945
BsmtFinType2	2.602740
BsmtExposure	2.602740
BsmtCond	2.534247
BsmtQual	2.534247
BsmtFinType1	2.534247
MasVnrArea	0.547945
Electrical	0.068493
Condition2	0.000000
BldgType	0.000000
Neighborhood	0.000000
LandSlope	0.000000
LotConfig	0.000000
Condition1	0.000000
LandContour	0.000000
LotShape	0.000000
Street	0.000000
LotArea	0.000000
MSSubClass	0.000000
MSZoning	0.000000
Id	0.000000
Utilities	0.000000
HouseStyle	0.000000
Foundation	0.000000
ExterQual	0.000000
ExterCond	0.000000
BsmtUnfSF	0.000000
TotalBsmtSF	0.000000
Heating	0.000000
BsmtFinSF1	0.000000
Exterior2nd	0.000000
Exterior1st	0.000000
RoofMatl	0.000000
RoofStyle	0.000000
YearRemodAdd	0.000000
OverallQual	0.000000
YearBuilt	0.000000
OverallCond	0.000000
BsmtHalfBath	0.000000
BsmtFullBath	0.000000
GrLivArea	0.000000
LowQualFinSF	0.000000
2ndFlrSF	0.000000
1stFlrSF	0.000000
CentralAir	0.000000
HeatingQC	0.000000
BsmtFinSF2	0.000000

```
Fireplaces      0.000000
TotRmsAbvGrd    0.000000
KitchenQual     0.000000
KitchenAbvGr    0.000000
Functional      0.000000
FullBath        0.000000
HalfBath        0.000000
GarageCars      0.000000
GarageArea      0.000000
BedroomAbvGr    0.000000
PavedDrive      0.000000
EnclosedPorch   0.000000
3SsnPorch       0.000000
OpenPorchSF     0.000000
WoodDeckSF      0.000000
PoolArea        0.000000
ScreenPorch     0.000000
MiscVal         0.000000
MoSold          0.000000
YrSold          0.000000
SaleType        0.000000
SaleCondition   0.000000
SalePrice       0.000000
dtype: float64
```

PoolQC (Qualidade da piscina) = 99.520548% NONE

MiscFeature (Recursos Extras / Diversos) = 96.301370% NONE

Alley (Beco ou Vuelas de acesso) = 93.767123% NONE

Fence (Cerca) = 80.753425% NONE

MasVnrType (Revestimento de Alvenaria) = 59.726027% NONE

```
FireplaceQu     47.260274
LotFrontage     17.739726
GarageQual      5.547945
GarageFinish    5.547945
GarageType      5.547945
GarageYrBlt     5.547945
GarageCond      5.547945
BsmtFinType2    2.602740
BsmtExposure    2.602740
BsmtCond        2.534247
BsmtQual        2.534247
BsmtFinType1    2.534247
MasVnrArea      0.547945
Electrical      0.068493
```

► Code

Use `exit()` or `Ctrl-D` (i.e. EOF) to exit

► Code

Anexando pacote: 'dplyr'

Os seguintes objetos são mascarados por 'package:stats':

filter, lag

Os seguintes objetos são mascarados por 'package:base':

intersect, setdiff, setequal, union

► Code

4.2 Tratamento de outliers

4.3 Transformações

5. Estatística Descritiva

5.1 Tabelas

Para análise inicial escolhemos a variável resposta, Preço de Venda (SalePrice), o tamanho do lote em pés quadrados (LotArea), a capacidade de carros na garagem (GarageCars), e a quantidade de quartos (BedroomAbvGr).

► Code



	Média	Mediana	Desvio Padrão
SalePrice	180921.195890	163000.0	79442.502883
LotArea	10516.828082	9478.5	9981.264932
GarageCars	1.767123	2.0	0.747315
BedroomAbvGr	2.866438	3.0	0.815778

► Code


	Média	Mediana	Desvio Padrão	CV(%)
SalePrice	180921.20	163000.0	79442.50	43.91
LotArea	10516.83	9478.5	9981.26	94.91
GarageCars	1.77	2.0	0.75	42.29
BedroomAbvGr	2.87	3.0	0.82	28.46

- média
- mediana
- dp
- CV (%)

5.2 Gráficos

[► Code](#)[► Code](#)[► Code](#)

Boxplot de SalePrice



- histograma

- boxplot
- densidade

6. Análise exploratória

7. Modelagem estatística

8. Diagnóstico do modelo

9. Seleção do melhor modelo

10. Discursão dos resultados

11. Conclusões

12. Referências